Segmentation de glaciers alpins à l'aide d'Attention U-Net sur des images satellites

Pierre Emery[1] **Mohamed Atmani**[1] **Fatou Ndao**[1]

[1]Université de Montréal

La fonte accélérée des glaciers alpins menace l'approvisionnement en eau potable, l'irrigation et la production hydroélectrique de régions entières, et augmente les risques de crues glaciaires et d'effondrements en aval. Suivre leur évolution de manière automatisée et précise permet d'anticiper ces impacts. Ce travail propose un pipeline complet de segmentation supervisée de l'étendue glaciaire à partir d'images Sentinel-2 et des contours GLIMS, incluant un score de qualité pour filtrer les scènes affectées par les nuages, les ombres et la neige saisonnière. Un modèle U-Net avec Attention Gates entraîné sur des glaciers du Caucase atteint un IoU de test de 0,83 (0,82 sur les Alpes, 0,84 sur les Andes), démontrant une capacité de généralisation inter-régions. Nous comparons plusieurs stratégies de régularisation ainsi qu'un modèle alternatif (DeepLabV3+), et montrons que notre U-Net, 5× plus léger, atteint des performances supérieures au modèle pré-entraîné.

1 Introduction

Les glaciers constituent des indicateurs particulièrement sensibles du changement climatique. Leur recul accéléré au cours des dernières décennies a des conséquences concrètes : modification des régimes hydrologiques alimentant l'eau potable, l'irrigation et l'hydroélectricité, perturbation des écosystèmes de montagne, et augmentation de certains risques naturels tels que la formation de lacs glaciaires instables ou les crues soudaines. Suivre leur évolution de manière automatisée et précise est donc essentiel pour anticiper et gérer ces impacts.

L'imagerie satellitaire, en particulier le programme Sentinel-2 [Drusch et al., 2012], offre aujourd'hui une couverture régulière et à haute résolution de la surface terrestre, ouvrant la voie à des approches d'apprentissage automatique pour la cartographie glaciaire. Parallèlement, des bases de données telles que GLIMS (*Global Land Ice Measurements from Space*) [Raup et al., 2007] fournissent des contours datés pour des milliers de glaciers à travers le monde, constituant une source de supervision exploitable pour l'entraînement de modèles de segmentation.

Ce projet formule la cartographie glaciaire comme une tâche de segmentation binaire supervisée. Il propose un pipeline complet allant de la construction d'un jeu de données avec des masques de supervision, à l'entraînement et l'évaluation de modèles de segmentation supervisée. Nous formulons la tâche comme une segmentation binaire : à partir d'un composite d'images Sentinel-2, le modèle doit prédire un masque distinguant les pixels glaciaires du terrain environnant. Nous nous concentrons en particulier sur deux enjeux pratiques : le contrôle de qualité des scènes satellitaires, qui conditionne toute la chaîne en aval, et la capacité du modèle à généraliser au-delà de la région d'entraînement.

 © Released under CC BY-NC-SA 4.0

2 Revue de la littérature

La cartographie précise des glaciers est un enjeu scientifique majeur car elle permet de suivre les effets du réchauffement climatique et d'évaluer son impact sur les ressources en eau.

Méthodes avant l'apprentissage automatique. Historiquement, la délimitation des glaciers était réalisée par des relevés de terrain et par photo-interprétation manuelle de photographies aériennes ou d'images satellites. Ces approches, bien que précises, sont extrêmement coûteuses en temps et en ressources humaines, et ne peuvent pas passer à l'échelle pour suivre l'évolution de dizaines de milliers de glaciers à travers le monde. Avec la démocratisation de l'imagerie satellite multispectrale, les méthodes semi-automatiques basées sur des indices spectraux se sont imposées, en particulier le *Normalized Difference Snow Index* (NDSI) [Hall et al., 1995], qui exploite le fort contraste entre la réflectance de la neige/glace dans le visible et son absorption dans le *Short-Wave Infrared* (SWIR). Combinés à des seuils manuels ou à des règles de décision, ces indices permettent une délimitation rapide mais peinent à distinguer la glace de la neige saisonnière, des nuages, ou de la roche claire, et nécessitent souvent un ajustement région par région ainsi qu'une correction manuelle des contours obtenus [Paul et al., 2002, **?**].

Observation satellite et bases de données glaciaires. La mise à disposition publique de données climatiques et d'images satellites a joué un rôle majeur dans le développement de méthodes de segmentation plus robustes. Des bases de données comme la GLIMS *Glacier Database* [Raup et al., 2007], qui fournit des contours datés pour des milliers de glaciers à travers le monde, et des missions comme Sentinel-2 [Drusch et al., 2012], qui offre une couverture mondiale régulière en 13 bandes multispectrales, ont rendu possible l'entraînement supervisé de modèles de segmentation à grande échelle.

Apprentissage profond et segmentation glaciaire. Les méthodes d'apprentissage profond, en particulier les réseaux de neurones convolutionnels (CNN) [LeCun et al., 1998], ont montré des performances nettement supérieures aux approches par indices spectraux pour la segmentation glaciaire. L'architecture U-Net [Ronneberger et al., 2015], initialement conçue pour la segmentation médicale, est devenue un standard en télédétection grâce à sa structure encodeur-décodeur et ses *skip connections* qui préservent les détails spatiaux. Parallèlement, des architectures plus lourdes comme DeepLabV3+ [Chen et al., 2018], utilisant des convolutions dilatées et un *backbone* pré-entraîné sur ImageNet, ont montré des résultats état-de-l'art en segmentation sémantique sur des images naturelles.

Approche proposée. Dans la continuité de ces travaux, nous mettons en œuvre un pipeline complet de segmentation supervisée de glaciers à partir d'images Sentinel-2 multispectrales (5 bandes), en utilisant les contours GLIMS comme vérité terrain. Notre étude s'articule autour de trois axes : (i) la construction d'un jeu de données à partir de scènes brutes, incluant un filtrage qualité basé sur la couche SCL de Sentinel-2 pour écarter les images trop nuageuses ou ombragées ; (ii) l'évaluation de la généralisation inter-régions, en entraînant sur le Caucase et en testant sur les Alpes et les Andes ; (iii) la comparaison entre un U-Net enrichi d'Attention Gates [Oktay et al., 2018] entraîné *"from scratch"* et un DeepLabV3+ pré-entraîné sur ImageNet, afin d'évaluer l'intérêt du pré-entraînement sur images naturelles pour une tâche multispectrale.

3 Jeu de données

Notre pipeline comporte trois étapes : le nettoyage des contours GLIMS, la récupération et le filtrage des images Sentinel-2, puis la rastérisation des polygones en masques binaires.

Les outlines de GLIMS Glacier Database constituent notre source de supervision, mais nécessitent un nettoyage préalable pour apparier les données avec les images satellites utilisées. Nous conservons uniquement les outlines datés entre 2016 et 2026 puisque nous utilisons exclusivement des produits Sentinel-2 L2A, disponibles depuis 2019, période à partir de laquelle l'ESA produit systématiquement le niveau L2A avec une couche SCL fiable. Les doublons et entrées redondantes sont supprimés, et seuls les champs d'identification et de géométrie sont retenus. Pour les images satellites, le modèle prend en entrée 5 bandes spectrales : Blue, Green, Red, NIR et SWIR16. Les bandes de proche infrarouge et infrarouge à courte ondes permettent de séparer glacier, eau et roche grâce à leurs réponses spectrales distinctes.

3.1 Analyse de qualité et sélection des scènes

La majorité des scènes récupérées étaient initialement inexploitables en raison de la neige saisonnière, de nuages ou des ombres couvrant les glaciers. Pour filtrer les images, nous exploitons la couche *Scene Classification Layer* (SCL) des produits Sentinel-2 L2A et définissons un score de qualité spatiale :

$$\text{score} = w_1\, f_{\text{cloud, glacier}} + w_2\, f_{\text{shadow, glacier}} + w_3\, f_{\text{snow, ring}} + w_4\,(1 - f_{\text{valid}})$$

Ce score distingue les pixels à l'intérieur du glacier de ceux dans une couronne extérieure, pénalisant les nuages et ombres sur le glacier ainsi que la neige autour (qui brouille les contours). La neige sur le glacier n'est pas pénalisée, car le SCL classe la glace permanente comme neige/glace, ce qui créerait un plancher faussement élevé.

Les scènes sont recherchées dans une fenêtre temporelle étroite de 2 à 3 semaines à la fin de l'été (par exemple mi-septembre à début octobre pour les Alpes), période où la couverture de neige saisonnière est minimale et les contours glaciaires sont les plus visibles. Malgré ce filtrage temporel et le score de qualité, les meilleures scènes individuelles présentaient fréquemment des nuages résiduels couvrant partiellement le glacier. Pour y remédier, nous construisons un composite médian à partir des 3 scènes ayant les meilleurs scores au sein de cette fenêtre.

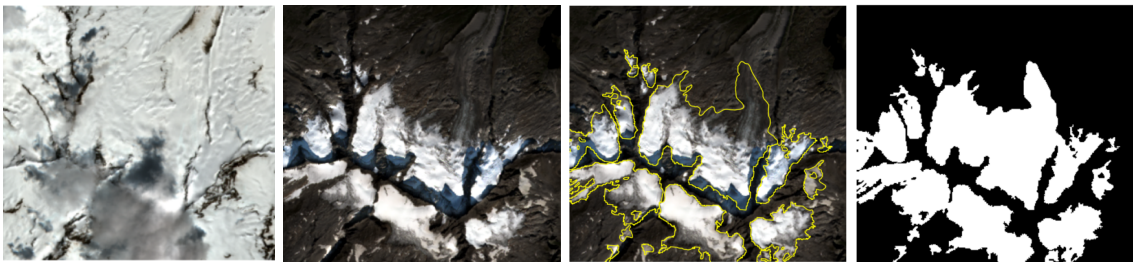

(a) Avant stratégie (b) Après stratégie (c) Superposition avec contours (d) Masque de supervision

Figure 1: Construction du jeu de données : différence avant/après la stratégie de sélection et création des masques.

3.2 Rastérisation et création des masques

Chaque composite est centré sur un glacier principal, sélectionné parmi les glaciers de surface suffisante ($\geq 0{,}5\,\mathrm{km}^2$) pour lesquels un contour GLIMS daté à moins de 3 ans de l'image satellite est disponible. Cependant, l'image de 320×320 pixels capture également les glaciers voisins, pour lesquels le contour le plus récent peut être plus ancien et donc moins fidèle à la réalité au moment de l'acquisition. Pour chacun de ces glaciers secondaires, nous sélectionnons le contour GLIMS le plus proche temporellement de l'image.

Les polygones GLIMS sont ensuite reprojetés et rastérisés sur la grille Sentinel-2 pour produire des masques binaires alignés pixel à pixel, servant pour la supervision de l'apprentissage. Afin de contrôler la qualité de ces masques, nous affichons chaque composite avec ses contours superposés et rejetons manuellement les images pour lesquelles le décalage entre les contours et l'étendue glaciaire visible est trop important. Au total, le jeu de données retenu compte 582 paires composite-masque réparties sur trois régions.

3.3 Séparations des ensembles d'entraînement, validation et test

Pour éviter les fuites d'information, nous adoptons une séparation par région pour l'entraînement, et une séparation aléatoire sans chevauchement pour la validation et le test, le dataset final est donc séparé ainsi : entraînement sur le Caucase (346 paires), validation et test sur les Alpes et Andes mélangés (118 paires respectivement). Le split est fixé par une *random seed* et sauvegardé pour garantir la reproductibilité. Ce protocole permet d'évaluer la généralisation à des chaînes non vues à l'entraînement : les Alpes (plus similaire au Caucase) et les Andes (une chaîne différente).

4 Modèle et choix méthodologiques

4.1 Architecture : Attention U-Net

Nous utilisons un U-Net [Ronneberger et al., 2015] augmenté d'*Attention Gates* [Oktay et al., 2018] comme modèle principal. Cette architecture encodeur-décodeur est particulièrement adaptée à notre tâche car la segmentation glaciaire requiert à la fois une compréhension sémantique globale (distinguer la glace des nuages, de la neige saisonnière ou de la roche claire) et une précision spatiale au pixel près pour délimiter les contours.

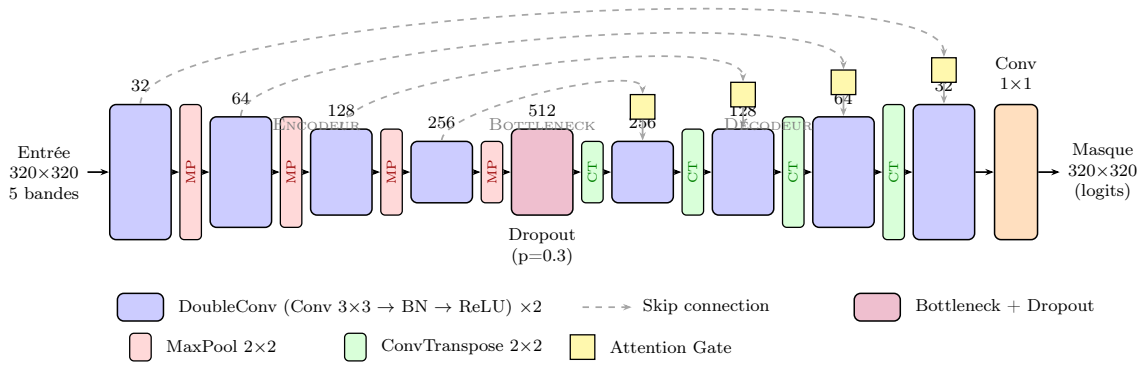

Figure 2: Architecture U-Net avec Attention Gates utilisée pour la segmentation glaciaire.

L'encodeur enchaîne des blocs de double convolution 3×3 (BatchNorm [Ioffe and Szegedy, 2015] + ReLU) et des max-pooling 2×2, selon la séquence de filtres $[32, 64, 128, 256]$. Le *bottleneck* à 512 filtres inclut un *Dropout* spatial [Srivastava et al., 2014] ($p = 0{,}3$) qui masque des canaux entiers de *feature maps* plutôt que des neurones individuels, ce qui régularise au point de plus forte compression. Le décodeur remonte symétriquement la résolution via des convolutions transposées 2×2, avec des *skip connections* [He et al., 2015] qui préservent l'information de localisation perdue par le *pooling*. Avant chaque concaténation, un *Attention Gate* filtre le signal de l'encodeur : le signal du décodeur (sémantiquement riche) guide un masque d'attention appris qui pondère chaque pixel du signal de l'encodeur (spatialement précis), ce qui focalise le décodeur sur les zones glaciaires plutôt que sur le fond. Une convolution 1×1 finale produit les logits.

Le modèle prend en entrée des patches de 5 bandes Sentinel-2 (B, G, R, NIR, SWIR16) de taille 320×320 pixels (multiple de 2^4 imposé par les 4 max-pooling) et produit un masque binaire de même résolution, pour ∼7,8M paramètres entraînables.

4.2 Modèle de comparaison : DeepLabV3+

Pour situer les performances de notre U-Net, nous comparons avec DeepLabV3+ [Chen et al., 2018] à *backbone* ResNet50 [He et al., 2016] pré-entraîné sur ImageNet. Ce modèle capture le contexte multi-échelle via un module *Atrous Spatial Pyramid Pooling* (ASPP) de convolutions dilatées en parallèle. Avec ses ∼42M paramètres (environ 5× plus que notre U-Net) et son pré-entraînement, il représente une référence exigeante.

Pour l'adapter à nos 5 bandes d'entrée, nous remplaçons la première couche convolutive ($3 \to 5$ canaux) en conservant les poids pré-entraînés pour les canaux RGB et en initialisant les canaux NIR (*near infrared*) et SWIR avec la moyenne des poids RGB existants. La tête de classification est réinitialisée pour la segmentation binaire, puis l'ensemble du modèle est *fine-tuné* sur nos données avec le même protocole que le U-Net, à l'exception du taux d'apprentissage.

4.3 Fonction de perte et métrique d'évaluation

Les métriques utilisées sont standard pour les tâches de segmentation. Pendant l'apprentissage, le modèle optimise une fonction de perte combinant la *Binary Cross-Entropy* (BCE) et la *Dice Loss* ; le modèle est ensuite sélectionné et évalué selon l'*Intersection over Union* (IoU) [Long et al., 2014] :

$$\mathcal{L} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Dice}}, \quad \mathcal{L}_{\text{Dice}} = 1 - \frac{2\,|P \cap T|}{|P| + |T|}, \quad \text{IoU} = \frac{|P \cap T|}{|P \cup T|}$$

Les deux pertes sont complémentaires : la BCE, calculée pixel par pixel, fournit un gradient dense et bien conditionné qui stabilise la convergence, tandis que la Dice Loss, calculée globalement, optimise directement le recouvrement et gère le déséquilibre de classes fréquent en segmentation glaciaire. L'IoU pénalise à la fois les faux positifs et les faux négatifs, et admet une interprétation géographique directe : un IoU de 0,7 signifie que 70 % de la surface prédite et de la surface réelle se recouvrent.

4.4 Augmentation de données

Pour réduire le surapprentissage, nous appliquons des augmentations à la volée pendant l'entraînement. À chaque *epoch*, chaque image est transformée aléatoirement par une

combinaison indépendante de retournements horizontal et vertical (50 % chacun), rotations de 90°/180°/270° (75 %), bruit gaussien ($\sigma = 0{,}02$, 50 %), et scaling par bande ($\times 0{,}9$ à $\times 1{,}1$, 50 %), environ 98 % des images subissant au moins une transformation par *epoch*. Les transformations géométriques sont appliquées de manière synchronisée à l'image et au masque. Les rotations arbitraires sont pertinentes pour des images satellite sans orientation privilégiée ; le bruit et le scaling par bande simulent la variabilité atmosphérique et les conditions d'illumination.

4.5 Hyperparamètres

L'entraînement utilise AdamW [Loshchilov and Hutter, 2017] avec un taux d'apprentissage initial de 10^{-3} réduit à 10^{-6} par un *scheduler cosinus*, et un *weight decay* de 10^{-4} [Loshchilov and Hutter, 2019]. Le DeepLabV3+ utilise un taux initial plus bas (5×10^{-4}) pour ne pas déstabiliser son *backbone* pré-entraîné. Le tableau 1 résume la configuration complète.

Table 1: Hyperparamètres d'entraînement.

Hyperparamètre	Valeur
Filtres encodeur (U-Net)	[32, 64, 128, 256]
Dropout (bottleneck)	0,3
Taille des patches	320×320 px
Bandes d'entrée	5 (B, G, R, NIR, SWIR16)
Taille de batch	4
Epoch	100
Optimiseur	AdamW
Taux d'apprentissage	10^{-3} (U-Net) / 5×10^{-4} (DeepLabV3+)
Scheduler	Cosinus ($\rightarrow 10^{-6}$)
Weight decay	10^{-4}

5 Résultats

Afin d'évaluer l'impact de chaque technique de régularisation et de comparer les architectures, nous entraînons cinq modèles : un U-Net sans aucune régularisation comme *baseline*, un U-Net avec *dropout* et *weight decay* mais sans augmentation (régularisation uniquement au niveau du modèle), un U-Net avec augmentation mais sans *dropout* ni *weight decay* (régularisation uniquement par les données), un U-Net combinant les deux approches, et DeepLabV3+ (ResNet50) comme modèle de référence pré-entraîné, avec augmentation et *weight decay*. Tous les modèles sont entraînés pendant 100 *epochs* sur le Caucase, et le meilleur *checkpoint* (IoU de validation maximal) est retenu pour l'évaluation sur le *test set*.

5.1 Courbes d'entraînement

La figure 3 montre l'évolution de la perte et de l'IoU pour une configuration U-Net avec augmentation, qui atteint un IoU de validation de $\sim$0,80. L'écart entre les courbes d'entraînement et de validation traduit un léger surapprentissage, attribuable à la taille limitée du jeu de données. Cet écart était sensiblement plus prononcé pour les configurations sans augmentation, et encore plus marqué pour le DeepLabV3+, dont le nombre de paramètres ($\sim$42M) est bien supérieur à la quantité de données disponibles.

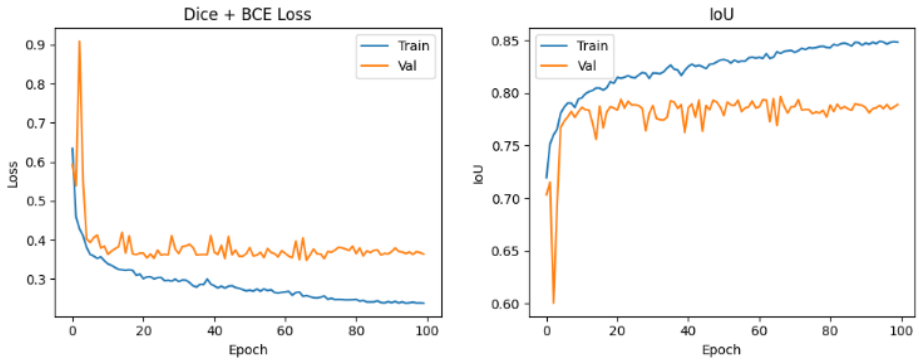

Figure 3: Courbes d'entraînement sur 100 *epoch* (configuration avec augmentation, sans *weight decay* ni *dropout*). Gauche : Dice + BCE Loss. Droite : IoU.

5.2 Étude d'ablation : impact de la régularisation

Le tableau 2 présente les résultats globaux sur l'ensemble de test. La *baseline* sans régularisation atteint déjà 0,817 d'IoU. Le *dropout* et le *weight decay* seuls n'apportent pas de gain (et dégradent même légèrement à 0,814), tandis que l'augmentation de données seule fait gagner 0,7 point (0,824). La combinaison des trois régularisations donne le meilleur résultat (0,830), suggérant que le *dropout* et *weight decay* n'apportent un bénéfice additif que lorsqu'ils sont combinés à l'augmentation.

Table 2: Résultats sur l'ensemble de test (toutes régions confondues).

Modèle	**IoU**	**Dice**	**Prec.**	**Recall**	**F1**	**Acc.**
U-Net : baseline (sans rég.)	0.8171	0.8993	0.9105	0.8885	0.8993	0.9172
U-Net : dropout+wd, no aug	0.8142	0.8976	0.9195	0.8767	0.8976	0.9168
U-Net : aug, no dropout/wd	0.8242	0.9036	0.9228	0.8852	0.9036	0.9214
U-Net : aug + dropout + wd	**0.8303**	**0.9073**	0.9131	**0.9015**	**0.9073**	**0.9233**
DeepLabV3+ (ResNet50)	0.8128	0.8967	**0.9259**	0.8694	0.8967	0.9167

5.3 Comparaison architecturale : U-Net vs DeepLabV3+

Le DeepLabV3+ pré-entraîné sur ImageNet (∼42M paramètres) obtient un IoU de 0,813, inférieur à notre meilleur U-Net (0,830, ∼7,8M paramètres). Ce résultat s'explique par plusieurs facteurs : (1) le backbone ResNet50 est optimisé pour 3 canaux RGB et des photos naturelles, pas pour des images satellite à 5 bandes — l'adaptation de la première couche convolutive ne suffit pas à réajuster les représentations profondes en 100 *epochs* ; (2) la capacité supplémentaire du DeepLabV3+ est surdimensionnée pour notre tâche de segmentation binaire relativement simple ; (3) le U-Net, entraîné *from scratch*, apprend des *features* directement adaptées aux propriétés spectrales des glaciers.

5.4 Résultats par région

Le tableau 3 détaille les performances par région. Un résultat notable est que tous les modèles performent mieux sur les Andes que sur les Alpes, alors que le Caucase (*train*) est géographiquement plus proche des Alpes. Cela s'explique probablement par la taille plus grande des glaciers andins dans notre dataset.

Table 3: Comparaison des modèles par région de test.

Modèle	Région	IoU	Dice	Prec.	Recall	F1	Acc.
U-Net : baseline (sans rég.)	Alpes	0.8143	0.8976	**0.9396**	0.8592	0.8976	0.9291
	Andes	0.8195	0.9008	0.8868	0.9153	0.9008	0.9027
U-Net : dropout+wd, no aug	Alpes	0.8146	0.8978	0.9378	0.8611	0.8978	0.9291
	Andes	0.8139	0.8974	0.9038	0.8911	0.8974	0.9016
U-Net : aug, no dropout/wd	Alpes	0.8193	0.9007	0.9420	0.8628	0.9007	**0.9312**
	Andes	0.8285	0.9062	0.9065	0.9058	0.9062	0.9095
U-Net : aug + dropout + wd	Alpes	**0.8198**	**0.9010**	0.9331	**0.8709**	**0.9010**	0.9307
	Andes	**0.8396**	**0.9128**	0.8966	**0.9297**	**0.9128**	**0.9143**
DeepLabV3+	Alpes	0.8118	0.8961	0.9326	0.8624	0.8961	0.9276
	Andes	0.8138	0.8973	0.9199	0.8758	0.8973	0.9033

5.5 Exemple de prédictions

La figure 4 présente quelques exemples de prédictions sur l'ensemble de test. Sur cette carte de différence, il faut interpréter les vrai positifs comme de la glace correctement identifiée, les faux positifs comme des pixels prédits comme glace alors que le masque GLIMS indique du fond et les faux négatifs comme de la glace manquée par le modèle.

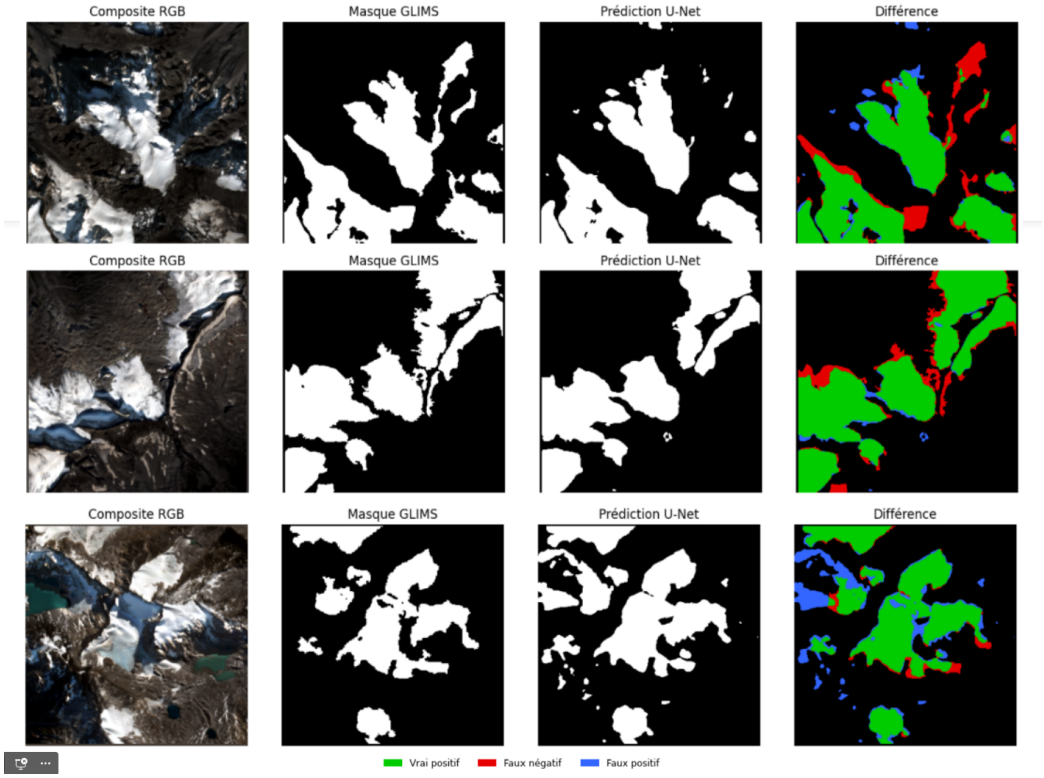

Figure 4: Prédictions sur des composites de test : composite Sentinel-2, masque GLIMS, prédiction U-Net et carte de différence (vert : vrai positif, bleu : faux positif, rouge : faux négatif).

Globalement, le modèle parvient à capturer la forme générale des glaciers et à distinguer les zones englacées du terrain rocheux, bien que certaines frontières restent imprécises. Une observation importante concerne les zones rouges et bleues qui apparaissent parfois dans des régions où l'image RGB ne laisse pas clairement voir de glace : ces divergences ne traduisent pas nécessairement des erreurs du modèle, mais reflètent en partie le bruit du jeu de données. D'une part, certains glaciers sont recouverts de débris rocheux et sont spectralement indistinguables de la roche environnante dans les bandes visibles ; d'autre part, les masques GLIMS eux-mêmes ne sont pas parfaits.

6 Conclusions

Ce projet démontre la faisabilité d'un pipeline complet de segmentation glaciaire, de la construction du jeu de données à l'évaluation de modèles de deep learning. Le filtrage qualité basé sur la couche SCL permet d'écarter efficacement les scènes inexploitables et de construire des composites lisibles. Notre meilleur modèle, un U-Net avec Attention Gates combinant augmentation de données, *dropout* et *weight decay*, atteint un IoU de test de 0,83 (0,82 sur les Alpes, 0,84 sur les Andes), confirmant une capacité de généralisation inter-régions.

L'étude d'ablation montre que l'augmentation de données est la régularisation la plus efficace pour notre tâche, réduisant significativement le surapprentissage par rapport à la *baseline*. L'ajout de dropout et weight decay apporte un gain supplémentaire modeste mais consistant, particulièrement sur la région la plus éloignée du *train set* (Andes). La comparaison avec un DeepLabV3+ pré-entraîné sur ImageNet ($\sim$42M paramètres) confirme qu'un modèle léger et spécialisé ($\sim$7,8M paramètres) peut surpasser un modèle généraliste surdimensionné sur une tâche de segmentation satellite multispectrale.

Plusieurs limitations doivent toutefois être soulignées. La taille du jeu de données reste modeste et le nombre de régions d'entraînement limité, ce qui restreint la diversité des configurations glaciaires apprises par le modèle. Les masques GLIMS comportent par ailleurs du bruit : datation hétérogène par rapport aux images Sentinel-2, imprécisions de contour, et difficulté intrinsèque à délimiter les glaciers couverts de débris, qui sont spectralement proches de la roche. Une partie des erreurs résiduelles du modèle est donc vraisemblablement attribuable à ces imperfections de la vérité terrain, ce qui limite mécaniquement l'IoU maximal atteignable.

7 Perspectives

Plusieurs pistes d'amélioration se dégagent naturellement de ces résultats. Un jeu de données plus large et diversifié, couvrant davantage de chaînes de montagnes (Himalaya, Alaska), permettrait de renforcer la généralisation. Une segmentation multi-classes distinguant lacs proglaciaires, végétation, roche et neige saisonnière réduirait les confusions aux frontières. Enfin, l'intégration d'une dimension temporelle, par exemple via un ConvLSTM [Shi et al., 2015] exploitant des séries annuelles de segmentations combinées à des données climatiques (précipitations, température), ouvrirait la voie à la prédiction de l'évolution future de l'étendue glaciaire. Un retour naturel à la question qui motivait initialement la cartographie des glaciers.

8 Contributions des membres

Pierre Emery. Conception et implémentation du pipeline complet pour le jeu de données. Implémentation du modèle U-Net et différents entraînements. Adaptation et entraînement de DeepLabV3+. Études d'ablation et évaluation finale sur l'ensemble de test. Contrôle de qualité manuel des images. Rédaction des rapports.

Mohamed Atmani. Rédaction de la revue de littérature. Participation à l'implémentation du modèle U-Net. Implémentation des Attention Gates. Participation à la rédaction et relecture des rapports.

Fatou Ndao. Participation aux discussions méthodologiques pour la qualité des images. Participation à la rédaction et relecture des rapports.

9 Utilisation d'un LLM

Nous avons utilisé Claude (Anthropic) à plusieurs étapes du projet. Claude Opus 4.6 a servi d'assistant au développement : aide à l'écriture du code, débogage, et discussion des choix méthodologiques. Certaines décisions d'implémentation ont été suggérées par le LLM, notamment le choix du scheduler cosinus pour la décroissance du taux d'apprentissage, le taux d'apprentissage plus bas pour le DeepLabV3+ (backbone pré-entraîné), et l'initialisation des bandes supplémentaires par la moyenne des poids RGB. Claude Sonnet 4.6 a été utilisé pour la correction linguistique du rapport.

References

Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 801–818, 2018.

Michael Drusch, Umberto Del Bello, Sebastien Carlier, Olivier Colin, Veronica Fernandez, Ferran Gascon, Bianca Hoersch, Claudia Isola, Paolo Laberinti, Philippe Martimort, et al. Sentinel-2: ESA's optical high-resolution mission for GMES operational services. *Remote Sensing of Environment*, 120:25–36, 2012.

Dorothy K Hall, George A Riggs, and Vincent V Salomonson. Development of methods for mapping global snow cover using moderate resolution imaging spectroradiometer data. *Remote Sensing of Environment*, 54(2):127–140, 1995.

Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *CoRR*, abs/1512.03385, 2015. URL `http://arxiv.org/abs/1512.03385`.

Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016. doi: 10.1109/CVPR.2016.90.

Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. *CoRR*, abs/1502.03167, 2015. URL `http://arxiv.org/abs/1502.03167`.

Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.

Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. *CoRR*, abs/1411.4038, 2014. URL `http://arxiv.org/abs/1411.4038`.

Ilya Loshchilov and Frank Hutter. Fixing weight decay regularization in adam. *CoRR*, abs/1711.05101, 2017. URL `http://arxiv.org/abs/1711.05101`.

Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularisation. *ICLR*, 2019.

Ozan Oktay, Jo Schlemper, Loic Le Folgoc, Matthew Lee, Mattias Heinrich, Kazunari Misawa, Kensaku Mori, Steven McDonagh, Nils Y Hammerla, Bernhard Kainz, et al. Attention u-net: Learning where to look for the pancreas. *arXiv preprint arXiv:1804.03999*, 2018.

Frank Paul, Andreas Kääb, Max Maisch, Tobias Kellenberger, and Wilfried Haeberli. The new remote-sensing-derived Swiss glacier inventory: I. Methods. *Annals of Glaciology*, 34: 355–361, 2002. doi: 10.3189/172756402781817941.

Bruce Raup, Adina Racoviteanu, Siri Jodha Singh Khalsa, Christopher Helm, Richard Armstrong, and Yves Arnaud. The GLIMS geospatial glacier database: a new tool for studying glacier change. *Global and Planetary Change*, 56:101–110, 2007.

Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241. Springer, 2015.

Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai-Kin Wong, and Wang-chun Woo. Convolutional lstm network: A machine learning approach for precipitation nowcasting. In *Advances in Neural Information Processing Systems*, volume 28, 2015.

Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 2014.